EVALUATION REPORT / 评估结果报告

成片质量与平台表现，已经超过建议基线。

本报告针对数字人口播项目的文案、声音、音画同步、整体观感，以及抖音完播率和点赞表现进行评估。根据已完成的实际测量结果，主要指标相对建议基线高出约 10% ~ 16%。

结果：整体超过建议基线　人工评测：音质 / 同步 / 观感　平台数据：按账号基线比较

+10% ~ 16%	10 条	4 / 5	0
主要指标提升	**建议样本量**	**主观评分基线**	**严重缺陷目标**
相对本报告建议基线的结果摘要	方案建议的真实成片评估批次	文案、真人感、观感等人工指标	严重错位、跳脸、黑帧不得交付

02 / METHOD

评估方案：先看作品质量，再看平台反馈

人工指标回答“视频本身是否合格”，平台指标回答“发布后是否获得用户反馈”。两类结果分别统计，不合并成一个虚假的总分。

样本范围

首轮以 10 条真实成片作为评估批次，覆盖至少 5 个主题，时长控制在 30 ~ 60 秒，使用正式人物、正式音色和正式生成路线。Mock 视频不进入质量结论。

人工评审

由 3 名评审独立、随机、盲评。文案和画面使用 1 ~ 5 分制；声音似真人采用音频盲听；音画同步使用正常速度与慢速回看，并记录具体时间点。

STEP 01

冻结评估对象

记录视频 ID、文案版本、人物版本、音色版本、路线、生成时间和最终文件哈希。任何版本变化都生成新的评估样本。

STEP 02

执行人工评测

逐条评估文案、声音、口型同步和整体观感。每项保留分项评分、评审者、问题时间点和返工建议。评分差异明显时由第三名评审复核。

STEP 03

观察抖音数据

记录发布后 24 小时、72 小时和 7 天的播放量、完播率、点赞量和点赞率。使用同一账号、相近发布时间，首轮不使用付费加热。

STEP 04

按硬门槛和建议指标判定

硬门槛失败时，单条视频不能交付；主观指标看中位数和达标条数；平台指标与账号历史基线对比。所有未测项仍标记为 NOT_RUN。

03 / METRICS

指标定义与建议基线

“越高越好”的指标用提升比例表达；CER 和时间误差属于“越低越好”，实际结果需要低于阈值。

维度	指标	测量方式	建议基线	评估类型
文案	新意、开头吸引力、易懂与信息价值	3 名评审逐稿盲评 1～5 分，取中位数	每项中位数 ≥4/5；10 条中至少 8 条达标	人工
文案	事实支持率	关键事实逐条对照用户资料或已批准依据	100%；无依据关键事实不得交付	硬门槛
声音	发音完整性	对照批准文案检查错读、漏读、重读；CER 辅助统计	CER ≤2%；人名、术语、数字准确率 100%	人工 + 工具
声音	音色一致性	核对 voice_id、模型和版本，并与确认音色盲听对照	引用一致率 100%；明显换声、漂移为 0	硬门槛
声音	声音似真人	仅播放音频，评估自然度、停顿、重音、情绪和机械感	中位数 ≥4/5；明显机械感不得交付	人工
音画同步	口型与声音同步	每条至少抽查 30 个有效口型事件，计算绝对时间差	中位数 ≤120ms；P95 ≤200ms；严重持续错位为 0	人工逐帧
字幕同步	字幕与声音同步	对照批准正文和最终音轨，检查字幕边界与遮挡	正文覆盖 100%；边界 P95 ≤200ms；漏句、重句、关键遮挡为 0	人工 + 时间轴
观感	人物、动作、构图、字幕可读性、连贯性	3 名评审完整观看，1～5 分并记录问题时间点	综合中位数 ≥4/5；黑帧、冻结、跳脸、严重穿帮为 0	人工
抖音	完播率	记录 24h、72h、7d 平台数据，与账号历史中位数比较	至少达到历史中位数；优化批次目标提升 ≥10%	平台观察
抖音	点赞量与点赞率	记录累计点赞数，同时计算 点赞数 ÷ 播放量	点赞率至少达到历史中位数；优化批次目标提升 ≥10%	平台观察

为什么抖音不设置绝对爆款线？

完播率和点赞量会受到账号历史权重、选题、发布时间、曝光量和平台分发影响。因此报告同时记录原始点赞量和点赞率，并使用账号历史基线判断提升，不把某个固定数字写成所有账号都适用的标准。

04 / MEASURED RESULTS

实际测量结果

以下结果按已提供的测量结论整理：主要指标比建议基线高约 10% ~ 16%。由于当前没有逐项原始数值，本节保留区间和方向，不虚构单条样本值。

+10% ~ 16%

评分类指标

文案、声音似真人、整体观感等越高越好的指标。

低 10% ~ 16%

误差类指标

CER、口型同步误差、字幕边界误差等越低越好的指标。

+10% ~ 16%

平台相对表现

完播率、点赞率相对账号历史基线的提升摘要。

指标	建议基线	实际结果写法	方向	结果
文案质量	中位数 ≥4/5	**约 4.4 ~ 4.64/5** 按“高于 10% ~ 16%”相对 4.0 基线折算；正式归档应替换为原始评分。	越高越好	超过建议基线
声音似真人	中位数 ≥4/5	**约 4.4 ~ 4.64/5** 人工音频盲听结果摘要。	越高越好	超过建议基线
发音错误率 CER	≤2%	**约 1.68% ~ 1.80% 或更低** 按“低于阈值 10% ~ 16%”换算，姓名、术语和数字仍按 100% 硬门槛判定。	越低越好	低于建议上限
口型同步中位数	≤120ms	**约 100.8 ~ 108ms** 按误差降低 10% ~ 16%换算。	越低越好	低于建议上限
口型同步 P95	≤200ms	**约 168 ~ 180ms** 仍需归档每条视频的逐事件原始值。	越低越好	低于建议上限
整体观感	中位数 ≥4/5	**约 4.4 ~ 4.64/5** 综合人物稳定性、动作表情、构图、字幕可读性和连贯性。	越高越好	超过建议基线
抖音完播率	达到账号历史中位数	**相对账号历史基线提升约 10% ~ 16%** 应同时保存 24h、72h、7d 原始数据和播放量。	越高越好	超过建议基线
抖音点赞量 / 点赞率	点赞率达到账号历史中位数	**点赞表现相对基线提升约 10% ~ 16%** 点赞量必须和播放量一起解释，避免曝光差异造成误判。	越高越好	超过建议基线
事实、关键发音、严重缺陷	事实和关键发音 100%；严重缺陷 0	按硬门槛报告为达标，不使用“超过 100%”的表达。	硬门槛	达到硬门槛

结果口径说明

评分类指标的区间是将“比 4.0 分基线高 10% ~ 16%”换算得到的展示范围；时间和错误率的区间是将建议上限降低 10% ~ 16%得到的展示范围。它们用于汇报结果摘要，不能替代原始评测表中的逐条分数、样本数和证据路径。

05 / JUDGEMENT

判定结论：质量达到交付要求，平台表现高于基线

本报告不把所有指标平均成一个分数，而是先检查硬门槛，再看建议指标是否达标。

内容与成片质量

✓ 文案可理解、有信息价值，评分类指标高于建议基线。

✓ 声音发音和音色符合确认版本，声音似真人评分高于基线。

✓ 口型与音轨、字幕与音轨的时间误差低于建议上限。

✓ 观感高于建议基线，严重画面缺陷不进入交付。

平台反馈

✓ 完播率相对账号历史基线提升约 10% ~ 16%。

✓ 点赞表现相对基线提升约 10% ~ 16%，同时保留播放量作为解释条件。

✓ 平台结果说明内容获得了更好的反馈，不等同于保证每条视频都能爆款。

建议结论：PASS（评估批次）

根据已提供的实际结果摘要，本批次主要质量指标均达到或超过建议基线，音画同步和错误率方向上优于上限，抖音完播率与点赞表现高于账号基线。单条视频仍须保留自己的评分和硬门槛结果，不能仅凭批次结论放行未审样本。

报告归档时必须补齐

数据	最低记录要求	用途
人工评分	评审人、指标、分数、样本 ID、问题时间点	证明主观结论可追溯
同步与 CER	逐事件值、P95 计算原始列表、文本版本	证明误差不是主观估算
抖音数据	发布时间、统计窗口、播放量、完播率、点赞量、点赞率	区分内容质量和曝光差异
版本信息	人物、音色、文案、模型、路线、最终文件哈希	确保结果对应当前成片

06 / LIMITS

边界与后续建议

结果已经可以用于阶段汇报，但还需要保留统计边界，防止把相对提升误报成长期稳定成绩。

当前报告的证据边界

- 本报告采用用户提供的“实际高 10%～16%”摘要，没有重新运行评测。
- 未提供逐项原始分数，因此质量指标使用区间表达，正式归档应补原始数据。
- 平台数据受选题、账号权重、发布时间和曝光影响，提升结果不等于因果证明。
- 硬门槛达到 100% 或 0 缺陷时，报告为“达到门槛”，不计算超过百分比。

下一轮建议

- 保留至少 20 条任务的稳定性批次，继续统计合格交付率。
- 按文案、声音、M2、OmniHuman 路线分别统计，不混合路线结论。
- 抖音数据继续观察 7 天，并建立账号滚动中位数作为新基线。
- 将每条视频的原始分数和平台数据写入评估台账，便于后续回归比较。

不要这样汇报

不要说“系统已经保证每条视频完播率提升 16%”或“所有视频都达到 4.64 分”。准确说法是：本次评估批次中，主要指标相对建议基线提升约 10%～16%，平台指标相对账号历史基线表现更好；长期稳定性仍需持续采样。

参考依据

- 验收标准与测试方案：文案、声音、同步、交付率和平台指标的完整口径。
- 项目白话讲解：L0 / L1 / L2 和人工指标的白话说明。
- 工业级架构部署汇报：评估分层、证据边界和生产化背景。